MÓDULO DE ESTUDIO · FUNDAMENTOS OSINT

Indexación Web, SEO, robots.txt y Google Dorking

Fundamentos de OSINT aplicados a Attack Surface Management (ASM)

ESTUDIANTE / PRACTICANTE

Jesús Alejandro Rodríguez Medina

ROL

DevSecOps / Analista de Ciberseguridad Jr.

PROYECTO MARCO

Attack Surface Management (ASM)

ÁREA DE ESTUDIO

OSINT / Reconocimiento Pasivo

FUENTE DE ESTUDIO

TryHackMe — Search Engines & Dorking

BLOQUES CUBIERTOS

4 (Crawlers · SEO/robots.txt · Sitemaps · Dorking)

OSINT Framework | OWASP WSTG — Information Gathering | Reconocimiento Pasivo

Código de Documento: REP-ASM-2026-OSINT01

◆ TIPO: ESTUDIO / TEÓRICO-PRÁCTICO

1. Ficha General del Documento

Campo	Detalle Corporativo / Académico
Estudiante / Practicante	Jesús Alejandro Rodríguez Medina
Rol	DevSecOps / Analista de Ciberseguridad Jr.
Proyecto Marco	Attack Surface Management (ASM)
Área de Estudio	OSINT / Reconocimiento Pasivo — Motores de Búsqueda
Estado del Módulo	COMPLETADO

2. Resumen Ejecutivo

Este documento resume el estudio de los mecanismos mediante los cuales los motores de búsqueda descubren, indexan y exponen información de Internet, así como su relevancia directa para tareas de OSINT (Open Source Intelligence) dentro de un programa de Attack Surface Management (ASM).

Se cubrieron cuatro bloques temáticos: **(1)** funcionamiento de crawlers e indexación, **(2)** SEO y el archivo robots.txt, **(3)** Sitemaps, y **(4)** Google Dorking / búsqueda avanzada. El hilo conductor entre los cuatro bloques es que comprender cómo un buscador indexa contenido permite después usar ese mismo índice como fuente de reconocimiento pasivo sobre la superficie públicamente visible de una organización.

Bloques Cubiertos

- **1.** Search Engines, Crawlers e Indexación
- **2.** SEO y robots.txt
- **3.** Sitemaps
- **4.** Google Dorking / Advanced Searching

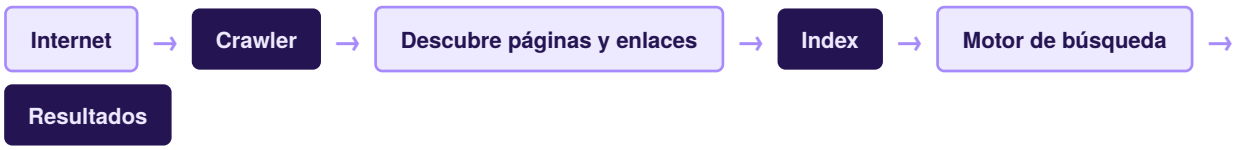
Relevancia para ASM

- Identificar qué información está públicamente indexada
- Detectar rutas y archivos expuestos sin escaneo activo
- Reconocimiento 100% pasivo (sin tocar el objetivo)
- Base para fases posteriores de OSINT dirigido

3. Bloque 1 — Search Engines, Crawlers e Indexación

Los motores de búsqueda funcionan como grandes indexadores de contenido de Internet. Para encontrar ese contenido utilizan programas automatizados llamados **crawlers** (también conocidos como *spiders* o arañas web).

Proceso simplificado



¿Qué descubre el crawler?

`palabras clave` `páginas` `archivos` `enlaces` `otras URLs`

El crawler puede seguir los enlaces encontrados en una página para descubrir contenido adicional, incluso en otros dominios (por ejemplo, partiendo de *mywebsite.com* y llegando a *anotherwebsite.com* a través de un enlace externo).

Crawler vs. Index

Crawler — Descubre

Recorre Internet, visita páginas y sigue enlaces para encontrar contenido nuevo.

Index — Almacena / Organiza

Registra el contenido descubierto y su ubicación, para que el motor de búsqueda pueda consultarlo posteriormente.

"El crawler descubre; el index registra; el search engine consulta."

4. Bloque 2 — SEO y robots.txt

SEO (Search Engine Optimisation)

Su objetivo es mejorar qué tan bien puede ser interpretado, rastreado y presentado un sitio por los motores de búsqueda. Influyen: compatibilidad entre navegadores, funcionamiento en dispositivos móviles, facilidad para que los crawlers recorran el sitio, uso de Sitemaps y palabras clave del contenido.

Facilidad de crawling + **Contenido / Keywords** + **Compatibilidad** + **Sitemap** = **SEO**

robots.txt

Archivo de texto ubicado normalmente en la raíz del dominio (p. ej. **ablog.com/robots.txt**) que proporciona instrucciones a los crawlers sobre qué contenido deberían o no deberían rastrear.

Directiva	Función
`User-agent`	Determina a qué crawler se aplica la regla. * = todos los crawlers.
`Allow`	Indica qué contenido puede rastrearse.
`Disallow`	Indica contenido que el crawler no debería rastrear.
`Sitemap`	Proporciona la ubicación del Sitemap del sitio.

```
User-agent: *
Allow: /
Sitemap: https://example.com/sitemap.xml
```

Significa: todos los crawlers pueden recorrer el sitio, y aquí está la ubicación del Sitemap.

```
User-agent: *
Disallow: /dont-index-me/
```

Significa: los crawlers no deberían recorrer **/dont-index-me/**.

```
User-agent: Bingbot
Allow: /
```

Ejercicio resuelto: permitir explícitamente a **Bingbot** recorrer todo el sitio.

> ⚠ **Consideración crítica de ciberseguridad**
>
> robots.txt **no** es un mecanismo de control de acceso. Declarar `Disallow: /admin/` no convierte esa ruta en privada — de hecho, el propio archivo puede revelar que esa ruta existe. **Disallow no equivale a autenticación ni autorización.**

Extensión de archivo de configuración: la respuesta correcta del ejercicio fue `.conf`, extensión común asociada a archivos de configuración en entornos Unix/Linux.

5. Bloque 3 — Sitemaps

Un Sitemap funciona conceptualmente como un **mapa** del sitio web. Su función es ayudar al crawler a conocer las rutas necesarias para localizar el contenido.



En el material de referencia, los rectángulos representaban **routes** (rutas) y los elementos asociados representaban páginas de contenido.

Aspecto	Detalle
Formato típico	XML — comúnmente `sitemap.xml`
Comparación conceptual	Un "mapa" del sitio (map)
Camino hacia el contenido	Route
Ejemplo	`ablog.com/sitemap.xml`



El material compara esto con utilizar una *wordlist* en lugar de intentar adivinar nombres de archivos aleatoriamente: sin Sitemap, el crawler debe descubrir enlaces mientras recorre el sitio; con Sitemap, el rastreo es mucho más eficiente y contribuye directamente al SEO.

6. Bloque 4 — Google Dorking / Advanced Searching

Bloque especialmente relevante para OSINT y ASM. Google tiene una enorme cantidad de contenido previamente indexado; los **operadores avanzados** permiten filtrar ese índice para encontrar información específica — técnica conocida como **Google Dorking**.

Operador	Función	Ejemplo
`site:`	Limita la búsqueda a un dominio específico (DÓNDE buscar)	`site:bbc.co.uk flood defences`
`"..."`	Busca una frase exacta en lugar de palabras sueltas	`"flood defences"`
`filetype:`	Filtra por extensión de archivo (QUÉ tipo de archivo)	`site:bbc.co.uk filetype:pdf`
`intitle:`	Busca un término dentro del título de la página (QUÉ debe aparecer en el título)	`intitle:login`
`cache:`	Consulta la versión almacenada en caché de una URL por Google	`cache:example.com`

```
site:bbc.co.uk flood defences
```

Busca información sobre "flood defences" únicamente dentro de **bbc.co.uk**.

```
site:bbc.co.uk filetype:pdf
```

Busca archivos PDF indexados pertenecientes a bbc.co.uk — útil en OSINT para localizar documentos públicos que un usuario no encontraría navegando manualmente.

```
intitle:login
```

Busca páginas cuyo título contenga la palabra "login".

7. Relevancia para OSINT y ASM

La idea central que conecta los cuatro bloques con el proyecto de Attack Surface Management es: entender cómo un buscador descubre e indexa información permite después utilizar ese mismo índice como una **fuente OSINT** para conocer qué superficie de una organización es públicamente visible.

1. **Reconocimiento 100% pasivo:** Google Dorking permite obtener información sin realizar ninguna solicitud directa al objetivo, reduciendo el riesgo de detección.

2. **Auditar robots.txt como parte del ASM:** revisar qué rutas se declaran como Disallow puede revelar paneles administrativos u otras rutas sensibles que la organización intentó "ocultar" sin autenticación real.
3. **Revisar sitemap.xml del objetivo:** puede exponer rutas y secciones del sitio no enlazadas visiblemente desde la navegación principal.
4. **Combinar operadores** (site: + filetype: + intitle:) para localizar documentos, portales de acceso o archivos de configuración indexados accidentalmente.

8. Chuleta de Referencia Rápida

SEARCH ENGINE

- **Crawler** → descubre
- **Index** → registra / organiza

SEO

- Keywords
- Crawling
- robots.txt
- Sitemap

ROBOTS.TXT

- **User-agent** → qué crawler
- **Allow** → permitir
- **Disallow** → evitar crawling
- **Sitemap** → ubicación del mapa

SITEMAP

- XML
- Map
- Routes

GOOGLE DORKING

- `site:` → dominio
- `filetype:` → tipo de archivo
- `intitle:` → título
- `"..."` → frase exacta

9. Aprobación y Conformidad

El presente reporte certifica la finalización exitosa del módulo de estudio sobre fundamentos de indexación web, SEO, robots.txt, Sitemaps y Google Dorking, dentro del programa de Prácticas Profesionales en Ciberseguridad y su aplicación al proyecto Attack Surface Management (ASM).

Jesús Alejandro Rodríguez Medina
Practicante de Ciberseguridad / DevSecOps

✓ MÓDULO COMPLETADO